

# *PROIECT SERII DE TIMP*

*Profesor coordonator: Prof.Univ.Dr Mihaela Simionescu*

*Simona Adnana Anghelina*

*UNIVERSITATEA DIN BUCUREȘTI FACULTATEA DE ADMINISTRAȚIE ȘI AFACERI*

# Partea I

În cadrul acestui proiect, am ales să analizez seria de timp privind **indicele prețurilor proprietăților rezidențiale din România** datorită relevanței economice și sociale semnificative pe care acest indicator o are. Piața imobiliară reprezintă un barometru esențial al sănătății economiei naționale, oferind informații despre tendințele economice, accesibilitatea locuințelor și comportamentul consumatorilor în raport cu bunurile de mare valoare.

Acest indicator a fost selectat pentru că reflectă dinamica uneia dintre cele mai importante piețe din România – cea a locuințelor, care este influențată de o multitudine de factori, atât locali, cât și globali. Evoluția prețurilor imobiliare este direct legată de fenomene economice precum:

- Ciclurile economice (expansiune și recesiune),
- Politicile fiscale și de creditare,
- Schimbările demografice și migrația internă.

În plus, datele despre prețurile locuințelor sunt relevante pentru multiple părți interesate: autorități publice care dezvoltă politici de locuințe, investitori imobiliari care urmăresc oportunități de profit și economiști care studiază stabilitatea financiară. Alegerea acestui indicator oferă posibilitatea unei analize aprofundate a trendurilor pe termen lung, a sezonality și a impactului șocurilor economice asupra pieței imobiliare.

Din punct de vedere metodologic, seria de timp privind prețurile rezidențiale oferă un set de date consistent și suficient de extins temporal, facilitând utilizarea tehnicilor moderne de analiză și prognoză. Totodată, acest indicator este unul de actualitate, având în vedere fluctuațiile recente ale pieței imobiliare în contextul globalizării, al schimbărilor economice post-pandemice și al creșterii cererii de locuințe accesibile.

Astfel, alegerea acestei serii de timp este fundamentată pe importanța practică, teoretică și analitică a indicatorului, asigurând premisele unui studiu relevant și bine fundamentat.

Sursa datelor este FRED și acoperă perioada începând cu anul 2009 până la anul 2024 (frecvența datelor fiind trimestrială) și reflectă dinamica pieței imobiliare, care este strâns legată de factori precum:

- Creșterea economică.
- Nivelul de trai și accesibilitatea locuințelor.
- Politicile fiscale și de creditare. Aceste aspecte fac din aceste date o resursă esențială pentru analiza comportamentului pieței și a economiei naționale.

Pentru a afla tipul de schema după care se descompune modelul am calculat media și abaterea valorilor pentru fiecare an într-o filă diferită numită "medie\_abatere". Pentru calcularea mediei

am folosit formula =AVERAGE(B2:B5) și pentru calcularea abaterii am folosit formula =STDEV(B2:B5). Apoi în foaia "date\_R" am structurat media și abaterea pentru fiecare an pentru o utilizare mai facilă în R.

Aceste calcule și transformări au fost necesare pentru a putea determina, mai departe, în R tipul schemei (aditivă sau multiplicativă) în funcție de care este descompusă seria de timp. Pentru a demonstra tipul schemei trebuie să realizăm o regresie liniară în care "Abaterea" să fie explicată de "Medie".

```
install.packages("readxl")
library("readxl")
my_data <- read_excel("C:/Users/simona/Desktop/2.01.xlsx")
model = lm(Abatere ~ Medie, data=my_data)
summary(model)
```

```
Call:
lm(formula = Abatere ~ Medie, data = my_data)
```

```
Residuals:
```

Min	1Q	Median	3Q	Max
-1.61863	-0.49819	-0.05231	0.38485	2.40195

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	1.201493	1.742046	0.690	0.502
Medie	0.007803	0.017165	0.455	0.656

```
Residual standard error: 1.034 on 14 degrees of freedom
```

```
Multiple R-squared: 0.01455, Adjusted R-squared: -0.05584
```

```
F-statistic: 0.2067 on 1 and 14 DF, p-value: 0.6564
```

Cum  $Pr(>|t|)=0.656$  mai mare decât 0.05, se acceptă ipoteza valorii nule a parametrului  $a_1$  la un nivel de semnificație de 5%. Deci, parametrul asociat mediei ( $a_1$ ) nu diferă semnificativ de 0 la un nivel de semnificație de 5%. Prin urmare, schema aditivă este adecvată în acest caz pentru descompunerea seriei de timp pentru **indicele prețurilor proprietăților rezidențiale din România**.

Deoarece schema seriei de timp este una aditivă, media mobilă este calculată prin media aritmetică a valorilor înregistrate folosind formula  $=((B2/2)+B3+B4+B5+(B6/2))/4$ . Fiind o medie mobilă de ordin 4 se pierde doi termeni de la început și doi termeni de la sfârșit.

După ce am calculat mediile mobile am creat o foaie de calcul denumită "trend" în care am pus valoarea mediilor mobile (Z) și variabila timp (t). Pentru estimarea trendului am folosit tendința

liniară cu relațiile  $a=M(Z) -bM(t)$  și  $b=M(t*Z)-M(t)M(Z)/M(t^2)-[M(t)]^2$ . După efectuarea calculelor care sunt disponibile în Excel am ajuns la ecuația trendului:  $T= 80.7715+0.5876*t$ .


	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	MM(4) Z	t	tZ	t^2	Trend												
2	*	*	*	*	*												
3	*	*	*	*	*												
4	107.4268	1	107.4268	1	81.3591												
5	105.9624	2	211.9247	4	81.9467												
6	104.3933	3	313.1799	9	82.5343												
7	101.6736	4	406.6946	16	83.1219												
8	98.53556	5	492.6778	25	83.7095												
9	95.60669	6	573.6401	36	84.2971												
10	92.57321	7	648.0125	49	84.8847												
11	89.33054	8	714.6443	64	85.4723												
12	86.82008	9	781.3807	81	86.0599												
13	85.25103	10	852.5103	100	86.6475												
14	83.99579	11	923.9537	121	87.2351												
15	83.36818	12	1000.418	144	87.8227												
16	83.15898	13	1081.067	169	88.4103												
17	82.94978	14	1161.297	196	88.9979												
18	82.94979	15	1244.247	225	89.5855												
19	83.0544	16	1328.87	256	90.1731												
20	82.7406	17	1406.59	289	90.7607												
21	82.11299	18	1478.034	324	91.3483												
22	81.58996	19	1550.209	361	91.9359												
23	81.38075	20	1627.615	400	92.5235												
24	81.69455	21	1715.586	441	93.1111												


Pentru a afla coeficienții de sezonaliitate am scăzut din seria inițială de date valoarea mediei mobile de ordiul 4 aferentă. După ce am aflat toți coeficienții de sezonaliitate am creat o nouă foaie de calcul numită "comp sezonieră" în care am așezat pe verticală anii și pe orizontală valoarea coeficienților sezonieri pe trimestre. Am calculat  $I_j$  pentru fiecare trimestru ca media aritmetică a valorilor trimestrului respectiv în fiecare an. Apoi am calculat media celor 12 valori obținute ( $I_j$ ). Cum această medie a fost  $-0.0050$ , diferită de 0 vom aplica factorul de corecție, adică vom scădea din fiecare  $I_j$  obținut anterior valoarea mediei aritmetice a lui  $I_j$  și va rezulta  $s_j$ . Am calculat media aritmetică a valorilui lui  $s_j$  determinat anterior care ne-a dat 0 .

	A	B	C	D	E	F	G	H
1		Trim I	TRIM II	TRIM III	TRIM IV			
2	2009	*	*	-1.1506	3.6610			
3	2010	-0.6276	0.4185	-0.6277	0.6276			
4	2011	-0.5230	1.0461	-1.4645	-2.4058			
5	2012	1.3598	1.1506	-1.9875	-0.9414			
6	2013	1.5690	0.6276	-0.7322	-0.1046			
7	2014	0.4184	-0.2093	-1.3598	-0.3138			
8	2015	1.5690	0.2092	-1.1506	-1.3598			
9	2016	0.5230	1.4644	-0.7322	-0.3138			
10	2017	-0.8368	2.0921	-0.9415	-0.6276			
11	2018	-0.3138	1.6736	-0.2092	0.0000			
12	2019	-0.7322	-0.1046	0.0000	-1.0460			
13	2020	2.0921	1.5690	-2.1967	-1.0460			
14	2021	0.2092	0.8368	-1.1506	0.1046			
15	2022	-0.3138	1.9874	-1.2552	1.4645			
16	2023	-0.1046	-2.1967	0.6276	0.4185			
17	2024	*	*	*	*			
18	$I_j$	0.3063	0.7546	-0.9554	-0.1255	0	-0.0050	
19	$s_j$	0.3113	0.7596	-0.9504	-0.1205		0.0000	
20								
21								
22								
23								
24	Com sezoniera	0.311308	0.759614	-0.9504	-0.12052			
25								
26								
27								

După ce am determinat coeficienții de sezonalitate pe fiecare trimestru i-am transpus în foaia principală a proiectului pentru a calcula valorile seriei de timp desezonalizate. Cum schema de descompunere este una aditivă vom calcula seria desezonalizată ca diferență între valoarea inițială a seriei și componenta sezonieră.

F4							
</							





Pentru previziunile valorilor următoare ale **indicelui prețurilor proprietăților rezidențiale din România** am folosit ecuația trendului determinată folosind mediile mobile

$$T = 80.7715 + 0.5876 \cdot t$$

Cum avem 58 de intrări, următorul  $t$  va fi 59. Am făcut previziuni pentru  $t=59, t=60$  și  $t=61$ .

Previziunile vor fi efectuate după formula  $\hat{y}_k = \hat{T}_k + \hat{s}$ , unde  $\hat{T}_k$  este trendul determinat anterior și  $\hat{s}$  este componenta sezonieră.

T=80.7715+0.5876*t				
t=59		$\hat{T}$	$\hat{s}$	$\hat{y}_k = \hat{T}_k + \hat{s}$
	7/1/2024	115.4399	-0.9504	114.4895
	10/1/2024	116.0275	-0.1205	115.9070
	1/1/2025	116.6151	0.3113	116.9264

## Partea a II-a

Problema șomajului reprezintă una dintre cele mai importante provocări socio-economice, având implicații majore asupra stabilității economice și sociale ale unei țări. În cadrul acestui proiect, ne-am concentrat asupra analizei econometrice a șomajului în rândul persoanelor cu studii universitare, o categorie semnificativă pentru înțelegerea relației dintre educație, piața muncii și dezvoltarea economică.

Persoanele cu studii superioare constituie un segment al forței de muncă care ar trebui să fie cel mai bine echipat pentru a se integra în piața muncii. Cu toate acestea, discrepanțele dintre competențele dobândite în cadrul sistemului educațional și cerințele pieței de muncă pot conduce la un nivel ridicat al șomajului în rândul acestora. Acest fenomen evidențiază ineficiențe structurale în economie și ridică semne de întrebare cu privire la eficacitatea politicilor educaționale și de ocupare a forței de muncă.

Datele utilizate în acest proiect au fost preluate de pe platforma Institutului Național de Statistică (INS), din setul de date intitulat „**Șomeri înregistrați pe categorii de șomeri, sexe, macror regiuni, regiuni de dezvoltare și județe**”. Aceste date, care acoperă o perioadă de timp cu frecvență anuală, reprezintă o sursă oficială și de încredere pentru analiza noastră.

Obiectivul principal al acestui proiect este construirea și interpretarea unui model econometric pentru seria de timp „Șomeri înregistrați cu studii universitare”. Prin intermediul acestui demers, urmărim:

- Analiza descriptivă a seriei de timp, incluzând tendințe, variabilitate și caracteristicile distribuției.
- Testarea staționarității seriei și identificarea eventualelor modele sezoniere.
- Construirea unui model econometric valid pentru a înțelege factorii determinanți ai evoluției acestei categorii de șomaj.
- Interpretarea rezultatelor obținute și oferirea de recomandări pentru politici publice.

Rezultatele acestui proiect vor contribui la o înțelegere mai profundă a factorilor care influențează șomajul în rândul persoanelor cu studii universitare și vor susține inițiativele de

reducere a șomajului structural. Această temă este de actualitate și are relevanță atât pentru mediul academic, cât și pentru decidenții politici, în vederea promovării unei forțe de muncă bine integrate și eficiente.

Am ales să realizez acest proiect utilizând limbajul **R** datorită avantajelor pe care acesta le oferă în analiza statistică și econometrică, mai ales pentru prelucrarea seriilor de timp. **R** este o platformă puternică și flexibilă, folosită pe scară largă în domeniul analizei datelor și al cercetării economice. Alegerea sa pentru acest proiect este justificată de mai multe motive:

1. **Instrumente avansate pentru analiza seriilor de timp**

R include o gamă largă de pachete dedicate analizei seriilor de timp, cum ar fi **forecast**, **tseries** și **urca**, care permit efectuarea cu ușurință a testelor de staționaritate, identificarea sezonality, estimarea modelelor ARIMA și alte tipuri de modele econometrice.

2. **Accesibilitate și ușurință în utilizare**

R oferă funcții intuitive pentru vizualizarea datelor și diagnosticarea modelelor, ceea ce face procesul de analiză mai eficient. Graficele și diagramele generate sunt de calitate superioară, contribuind la o interpretare clară a rezultatelor.

3. **Reproducibilitatea analizei**

În R, analiza poate fi automatizată și documentată pas cu pas. Acest lucru permite reproducerea rezultatelor, un aspect esențial pentru validitatea cercetării.

4. **Comunitatea extinsă și suportul tehnic**

R beneficiază de o comunitate globală de utilizatori și cercetători care contribuie constant cu pachete noi și îmbunătățiri. Resursele accesibile, cum ar fi tutorialele, forumurile și documentația, facilitează rezolvarea rapidă a problemelor.

5. **Adaptabilitate pentru proiecte complexe**

Pe lângă analiza seriilor de timp, R permite extinderea proiectului către alte tipuri de analize complexe, cum ar fi regresii neliniare sau analiza multivariată, oferind un mediu de lucru cuprinzător pentru cercetări econometrice.

Prin utilizarea R, am reușit să eficientizăm procesul de analiză, să asigurăm acuratețea calculelor și să generăm rezultate bine structurate, toate acestea contribuind la calitatea finală a proiectului.

Pentru a determina statistica descriptivă a seriei Somajului în rândul absolvenților de studii universitare am instalat librăria "pastec" care conține funcția "stat.desc". Am pus argumentele la basic, desc și norm TRUE pentru că avem nevoie de toate informațiile despre seria noastră.

```
install.packages("pastecs")
```

```
library(pastecs)
```

```
stat.desc(serie_somaj, basic=TRUE, desc=TRUE, norm=TRUE, p=0.95)
```



```
Console Terminal x
R 4.3.1 · C:/Users/simona/Desktop/
warning message:
package 'pastecs' was built under R version 4.3.3
> stat.desc(serie_somaj, basic=TRUE, desc=TRUE, norm=TRUE, p=0.95)
      x
nbr.val      3.100000e+01
nbr.null     0.000000e+00
nbr.na       0.000000e+00
min          7.399000e+03
max          5.003600e+04
range        4.263700e+04
sum          7.132540e+05
median       1.971700e+04
mean         2.300819e+04
SE.mean      1.984702e+03
CI.mean.0.95 4.053302e+03
var          1.221103e+08
std.dev      1.105035e+04
coef.var     4.802790e-01
skewness     8.784582e-01
skew.2SE     1.044450e+00
kurtosis     -5.221813e-02
kurt.2SE     -3.180917e-02
normtest.W   9.116159e-01
normtest.p   1.422998e-02
> library(urca)
```

## Indicatori descriptivi ai seriei de timp:

1. **Număr total de valori (nbr.val):**
  - 31 observații, corespunzând unui interval temporal anual între 1993 și 2023.
2. **Valori nule (nbr.null) și valori lipsă (nbr.na):**
  - Nu există valori nule sau lipsă în serie, ceea ce asigură completitudinea datelor.
3. **Statistici de poziție:**
  - **Minimul (min):** 7399 — cea mai mică valoare a șomerilor înregistrați în serie.
  - **Maximul (max):** 50036 — cea mai mare valoare a șomerilor înregistrați.
  - **Mediana:** 19717 — valoarea centrală a distribuției, ceea ce sugerează o concentrare a datelor sub media generală.
  - **Media (mean):** 23008.19 — valoarea medie anuală a șomerilor.
4. **Statistici de dispersie:**
  - **Intervalul (range):** 42637 — diferența dintre valorile maximă și minimă, indicând o variație substanțială a șomerilor înregistrați.
  - **Varianța (var):**  $1.221 \times 10^8$  — o măsură a variației totale a datelor.
  - **Abaterea standard (std.dev):** 11050.35 — indică gradul de dispersie a valorilor în jurul mediei.

- **Coeficientul de variație (coef.var):** 0.4803 — sugerează o variabilitate moderată raportată la medie.
5. **Statistici de formă a distribuției:**
- **Asimetria (skewness):** 0.8785 — indică o ușoară asimetrie pozitivă (coada dreaptă mai lungă).
  - **Testul pentru asimetrie (skew.2SE):** 1.0444 — sugerează că asimetria este semnificativă statistic.
  - **Curtosis (kurtosis):** -0.0522 — o valoare apropiată de zero indică o distribuție aproape normală.
  - **Testul pentru kurtosis (kurt.2SE):** -0.0318 — curtosisul nu este semnificativ statistic.
6. **Testul de normalitate (Shapiro-Wilk):**
- **W:** 0.9116 — o valoare mai mică decât 1 indică abaterea de la normalitate.
  - **p-valoare (normtest.p):** 0.0142 —  $p < 0.05$  sugerează că datele nu urmează o distribuție normală, ceea ce trebuie luat în considerare la alegerea metodelor econometrice.

Am verificat staționaritatea seriei în nivel, dar și în diferență dublă și simplă folosind testul ADF. Acest test verifică prezența unei rădăcini unitare sub trei forme diferite ale modelului: cu trend și intercept, doar cu intercept și fără niciunul. Dacă seria nu este staționară în prezența unui trend, testul ADF se aplică din nou fără trend, și dacă este necesar, și fără intercept.

```

22 library(urca)
23 vect<-serie_somaj
24 dvect<-diff(serie_somaj,differences = 1)
25 d2vect<-diff(serie_somaj,differences = 2)
26 dvect
27 d2vect
28
29 u1=ur.df(d2vect,type="trend",selectlags="AIC")
30 summary(u1)
31 #Statistica testului ADF este -5.8737, o valoare mai mica decat valoarea critica p
32 #deci se respinge ipoteza nula care specifica faptul ca seria in dubla diferenta a
33 u2=ur.df(d2vect,type="drift",selectlags = "AIC")
34 summary(u2)
35 u3=ur.df(d2vect,type="none",selectlags = "AIC")
36 summary(u3)
37
38
39 v1=ur.df(dvect,type="trend",selectlags = "AIC")
40 summary(v1)
41 v2=ur.df(dvect,type="drift",selectlags = "AIC")
42 summary(v2)
43 v3=ur.df(dvect,type="none",selectlags = "AIC")
44 summary(v3)
45
46
47 w1=ur.df(vect,type="trend",selectlags = "AIC")
48 summary(w1)
49 w2=ur.df(vect,type="drift",selectlags="AIC")

```

```

serii_2 x serii_ex2.R x
Source on Save Run
31 #Statistica testului ADF este -5.8737, o valoare mai mica decat valoarea cri
32 #decì se respinge ipoteza nula care specifica faptul ca seria in dubla difer
33 u2=ur.df(d2vect,type="drift",selectlags = "AIC")
34 summary(u2)
35 u3=ur.df(d2vect,type="none",selectlags = "AIC")
36 summary(u3)
37
38
39 v1=ur.df(dvect,type="trend",selectlags = "AIC")
40 summary(v1)
41 v2=ur.df(dvect,type="drift",selectlags = "AIC")
42 summary(v2)
43 v3=ur.df(dvect,type="none",selectlags = "AIC")
44 summary(v3)
45
46
47 w1=ur.df(vect,type="trend",selectlags = "AIC")
48 summary(w1)
49 w2=ur.df(vect,type="drift",selectlags="AIC")
50 summary(w2)
51 w3=ur.df(vect,type="none",selectlags="AIC")
52 summary(w3)
53
54 #seria este integrata de ordinul 1

```

```

> u1=ur.df(d2vect,type="trend",selectlags="AIC")
> summary(u1)

```

```

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-18616.8	-6078.8	-291.5	4916.0	26683.8

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	1257.9772	3932.7103	0.320	0.7520
z.lag.1	-1.7575	0.2992	-5.874	5.5e-06 ***
tt	-77.0982	232.8100	-0.331	0.7435
z.diff.lag	0.4171	0.1897	2.199	0.0382 *

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9401 on 23 degrees of freedom  
Multiple R-squared: 0.6855, Adjusted R-squared: 0.6444  
F-statistic: 16.71 on 3 and 23 DF, p-value: 5.564e-06

Value of test-statistic is: -5.8737 11.504 17.2521

Critical values for test statistics:  
1pct 5pct 10pct

```
tau3 -4.15 -3.50 -3.18
phi2 7.02 5.13 4.31
phi3 9.31 6.73 5.61
```

```
> u2=ur.df(d2vect,type="drift",selectlags = "AIC")
> summary(u2)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-18721.3  -5733.9  -519.5   4189.1  26736.6
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  101.7122  1775.9437   0.057   0.9548
z.lag.1       -1.7508    0.2929  -5.977 3.61e-06 ***
z.diff.lag     0.4138    0.1859   2.226  0.0357 *
---

```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 9225 on 24 degrees of freedom
Multiple R-squared:  0.684,    Adjusted R-squared:  0.6576
F-statistic: 25.97 on 2 and 24 DF,  p-value: 9.923e-07
```

Value of test-statistic is: -5.9766 17.8639

Critical values for test statistics:

```
    1pct    5pct   10pct
tau2 -3.58 -2.93 -2.60
phi1 7.06 4.86 3.94
```

```
> u3=ur.df(d2vect,type="none",selectlags = "AIC")
> summary(u3)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none

```
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-18621.1  -5633.0  -421.3   4292.0  26837.6
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
z.lag.1       -1.7509    0.2870  -6.100 2.24e-06 ***
z.diff.lag     0.4140    0.1821   2.273  0.0319 *
---

```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 9039 on 25 degrees of freedom  
Multiple R-squared: 0.6839, Adjusted R-squared: 0.6586  
F-statistic: 27.05 on 2 and 25 DF, p-value: 5.588e-07

Value of test-statistic is: -6.0998

Critical values for test statistics:

	1pct	5pct	10pct
tau1	-2.62	-1.95	-1.61

## Testul ADF cu Trend (u1)

- **Statistica testului (tau3):** Valoarea statisticii testului este **-5.8737**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -3.50
    - 10%: -3.18
  - Deoarece valoarea statisticii testului (-5.8737) este mai mică decât valoarea critică de 5% (-3.50), putem respinge ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Acest lucru sugerează că seria **nu are unitate de rădăcină** și este **staționară**.
- **Semnificația coeficienților:**
  - Coeficientul pentru variabila dependentă întârziată (z.lag.1) este **semnificativ** (p-valoare = 5.5e-06), ceea ce sugerează o relație negativă puternică între variabila întârziată și diferența.
  - Variabila „trend” (tt) nu este semnificativă (p-valoare = 0.7435), ceea ce înseamnă că termenul de tendință nu îmbunătățește semnificativ modelul.
  - Variabila „diferența întârziată” (z.diff.lag) este semnificativă (p-valoare = 0.0382), indicând o relație semnificativă.

## Testul ADF cu Derivă (u2)

- **Statistica testului (tau2):** Valoarea statisticii testului este **-5.9766**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -2.93
    - 10%: -2.60
  - Deoarece valoarea statisticii testului (-5.9766) este mai mică decât valoarea critică de 5% (-2.93), putem respinge ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Așadar, seria **nu are unitate de rădăcină** și este **staționară**.
- **Semnificația coeficienților:**
  - Coeficientul pentru variabila dependentă întârziată (z.lag.1) este semnificativ (p-valoare = 3.61e-06), ceea ce sugerează o relație negativă puternică între variabila întârziată și diferența.
  - Variabila „diferența întârziată” (z.diff.lag) este semnificativă (p-valoare = 0.0357), indicând o relație semnificativă.

## Testul ADF fără Trend și Derivă (u3)

- **Statistica testului (tau1):** Valoarea statisticii testului este **-6.0998**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -1.95
    - 10%: -1.61
  - Deoarece valoarea statisticii testului (-6.0998) este mai mică decât valoarea critică de 5% (-1.95), putem respinge ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Așadar, seria **nu are unitate de rădăcină** și este **staționară**.
- **Semnificația coeficienților:**
  - Coeficientul pentru variabila dependentă întârziată (z.lag.1) este semnificativ (p-valoare = 2.24e-06), ceea ce sugerează o relație negativă puternică între variabila întârziată și diferența.
  - Variabila „diferența întârziată” (z.diff.lag) este semnificativă (p-valoare = 0.0319), indicând o relație semnificativă.

## Concluzie:

În toate cele trei cazuri (trend, derivă, și niciunul), **testul ADF respinge ipoteza nulă a unității de rădăcină** la un nivel de semnificație de 5%. Aceasta înseamnă că seria **este staționară** și nu conține o unitate de rădăcină.

```
> v1=ur.df(dvect,type="trend",selectlags = "AIC")
> summary(v1)

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-8841  -4277  -1886   2061  27649

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 3160.1217  3113.9043   1.015  0.320303
z.lag.1      -1.0855    0.2450  -4.431  0.000177 ***
tt          -206.2243   179.4358  -1.149  0.261760
z.diff.lag    0.3049    0.1906   1.600  0.122619
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7509 on 24 degrees of freedom
```

Multiple R-squared: 0.482, Adjusted R-squared: 0.4172  
F-statistic: 7.444 on 3 and 24 DF, p-value: 0.001086

Value of test-statistic is: -4.4306 6.5702 9.8472

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.15	-3.50	-3.18
phi2	7.02	5.13	4.31
phi3	9.31	6.73	5.61

```
> v2=ur.df(dvect,type="drift",selectlags = "AIC")
> summary(v2)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-8054	-3621	-1624	1347	27643

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-24.9165	1429.0420	-0.017	0.986227
z.lag.1	-1.0282	0.2414	-4.259	0.000254 ***
z.diff.lag	0.2771	0.1902	1.457	0.157609

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7557 on 25 degrees of freedom  
Multiple R-squared: 0.4535, Adjusted R-squared: 0.4098  
F-statistic: 10.37 on 2 and 25 DF, p-value: 0.000525

Value of test-statistic is: -4.2592 9.0783

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.58	-2.93	-2.60
phi1	7.06	4.86	3.94

```
> v3=ur.df(dvect,type="none",selectlags = "AIC")
> summary(v3)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none

Call:

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-----	----	--------	----	-----

-8079 -3645 -1648 1323 27617

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
z.lag.1	-1.0281	0.2366	-4.345	0.000189 ***
z.diff.lag	0.2771	0.1865	1.486	0.149411

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7411 on 26 degrees of freedom

Multiple R-squared: 0.4537, Adjusted R-squared: 0.4117

F-statistic: 10.8 on 2 and 26 DF, p-value: 0.0003862

value of test-statistic is: -4.3454

Critical values for test statistics:

	1pct	5pct	10pct
tau1	-2.62	-1.95	-1.61

## Testul ADF cu Trend (v1)

- **Statistica testului (tau3):** Valoarea statisticii testului este **-4.4306**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -3.50
    - 10%: -3.18
  - Deoarece valoarea statisticii testului (-4.4306) este mai mică decât valoarea critică de 5% (-3.50), respingem ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Acest lucru sugerează că seria **nu are unitate de rădăcină** și este **staționară**.
- **Semnificația coeficientilor:**
  - Coeficientul pentru variabila dependentă întârziată (z.lag.1) este semnificativ (p-valoare = 0.000177), ceea ce sugerează o relație negativă semnificativă între variabila întârziată și diferența.
  - Variabila „trend” (tt) nu este semnificativă (p-valoare = 0.261760), ceea ce înseamnă că termenul de tendință nu îmbunătățește semnificativ modelul.
  - Variabila „diferența întârziată” (z.diff.lag) nu este semnificativă (p-valoare = 0.122619), ceea ce sugerează că nu are un impact semnificativ asupra modelului.

## Testul ADF cu Derivă (v2)

- **Statistica testului (tau2):** Valoarea statisticii testului este **-4.2592**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -2.93
    - 10%: -2.60
  - Deoarece valoarea statisticii testului (-4.2592) este mai mică decât valoarea critică de 5% (-2.93), respingem ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Așadar, seria **nu are unitate de rădăcină** și este **staționară**.



- **Semnificația coeficientilor:**
  - Coeficientul pentru variabila dependentă întârziată (z.lag.1) este semnificativ (p-valoare = 0.000254), indicând o relație negativă semnificativă între variabila întârziată și diferență.
  - Variabila „diferența întârziată” (z.diff.lag) nu este semnificativă (p-valoare = 0.157609), ceea ce sugerează că nu adaugă valoare semnificativă modelului.

### Testul ADF fără Trend și Derivă (v3)

- **Statistica testului (tau1):** Valoarea statisticii testului este **-4.3454**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -1.95
    - 10%: -1.61
  - Deoarece valoarea statisticii testului (-4.3454) este mai mică decât valoarea critică de 5% (-1.95), respingem ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Așadar, seria **nu are unitate de rădăcină** și este **staționară**.
- **Semnificația coeficientilor:**
  - Coeficientul pentru variabila dependentă întârziată (z.lag.1) este semnificativ (p-valoare = 0.000189), ceea ce sugerează o relație negativă semnificativă între variabila întârziată și diferență.
  - Variabila „diferența întârziată” (z.diff.lag) nu este semnificativă (p-valoare = 0.149411), ceea ce sugerează că nu are un impact semnificativ asupra modelului.

### Concluzie:

În toate cele trei cazuri (trend, derivă și niciunul), **testul ADF respinge ipoteza nulă a unității de rădăcină** la un nivel de semnificație de 5%, ceea ce înseamnă că seria **nu are unitate de rădăcină** și este **staționară**.

```
> w1=ur.df(vect,type="trend",selectlags = "AIC")
> summary(w1)

#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-8848  -2605  -1873   3095  26879

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  8758.4731  4168.9867   2.101  0.0459 *
z.lag.1       -0.3081    0.1303  -2.365  0.0261 *
tt          -101.5490   160.1433  -0.634  0.5318
z.diff.lag     0.3424    0.1915   1.788  0.0860 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7127 on 25 degrees of freedom
Multiple R-squared:  0.2263, Adjusted R-squared:  0.1335
F-statistic: 2.438 on 3 and 25 DF, p-value: 0.08813
```

value of test-statistic is: -2.365 2.0367 3.0459

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-4.15	-3.50	-3.18
phi2	7.02	5.13	4.31
phi3	9.31	6.73	5.61

```
> w2=ur.df(vect,type="drift",selectlags="AIC")
> summary(w2)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-9549  -2690  -1908   1954  26776
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  7196.8514  3324.9686   2.164  0.0398 *
z.lag.1       -0.3106    0.1287  -2.413  0.0232 *
z.diff.lag     0.3610    0.1871   1.930  0.0646 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 7045 on 26 degrees of freedom  
Multiple R-squared: 0.2139, Adjusted R-squared: 0.1534  
F-statistic: 3.537 on 2 and 26 DF, p-value: 0.04377

Value of test-statistic is: -2.4132 2.9212

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.58	-2.93	-2.60
phi1	7.06	4.86	3.94

```
> w3=ur.df(vect,type="none",selectlags="AIC")  
> summary(w3)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression none

Call:

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-8277.9	-2451.4	537.5	3012.9	29364.2

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
z.lag.1	-0.05450	0.05401	-1.009	0.322
z.diff.lag	0.21954	0.18686	1.175	0.250

Residual standard error: 7510 on 27 degrees of freedom  
Multiple R-squared: 0.07305, Adjusted R-squared: 0.004385  
F-statistic: 1.064 on 2 and 27 DF, p-value: 0.3591

Value of test-statistic is: -1.0091

Critical values for test statistics:

	1pct	5pct	10pct
tau1	-2.62	-1.95	-1.61

## Testul ADF cu Trend (w1)

- **Statistica testului (tau3):** Valoarea statisticii testului este **-2.365**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -3.50
    - 10%: -3.18
  - Deoarece valoarea statisticii testului (-2.365) este **mai mare** decât valoarea critică de 5% (-3.50), **nu respingem** ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Acest lucru sugerează că seria **are unitate de rădăcină și nu este staționară**.
- **Semnificația coeficienților:**

- Coeficientul pentru variabila dependentă întârziată (z.lag.1) este semnificativ (p-valoare = 0.0261), indicând o relație negativă semnificativă între variabila întârziată și diferența.
- Variabila „trend” (tt) nu este semnificativă (p-valoare = 0.5318), ceea ce înseamnă că termenul de tendință nu îmbunătățește semnificativ modelul.
- Variabila „diferența întârziată” (z.diff.lag) este aproape semnificativă (p-valoare = 0.0860), ceea ce sugerează o relație ușor semnificativă cu variabilele din model.

### Testul ADF cu Derivă (w2)

- **Statistica testului (tau2):** Valoarea statisticii testului este **-2.4132**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -2.93
    - 10%: -2.60
  - Deoarece valoarea statisticii testului (-2.4132) este **mai mare** decât valoarea critică de 5% (-2.93), **nu respingem** ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Așadar, seria **are unitate de rădăcină și nu este staționară**.
- **Semnificația coeficienților:**
  - Coeficientul pentru variabila dependentă întârziată (z.lag.1) este semnificativ (p-valoare = 0.0232), indicând o relație negativă semnificativă între variabila întârziată și diferența.
  - Variabila „diferența întârziată” (z.diff.lag) este aproape semnificativă (p-valoare = 0.0646), indicând o relație ușor semnificativă.


### Testul ADF fără Trend și Derivă (w3)

- **Statistica testului (tau1):** Valoarea statisticii testului este **-1.0091**.
  - Valori critice pentru niveluri de semnificație de 5%:
    - 5%: -1.95
    - 10%: -1.61
  - Deoarece valoarea statisticii testului (-1.0091) este **mai mare** decât valoarea critică de 5% (-1.95), **nu respingem** ipoteza nulă a unității de rădăcină la un nivel de semnificație de 5%.
  - Astfel, seria **are unitate de rădăcină și nu este staționară**.
- **Semnificația coeficienților:**
  - Coeficientul pentru variabila dependentă întârziată (z.lag.1) nu este semnificativ (p-valoare = 0.322), ceea ce sugerează că nu există o relație semnificativă între variabila întârziată și diferența.
  - Variabila „diferența întârziată” (z.diff.lag) nu este semnificativă (p-valoare = 0.250), ceea ce indică faptul că nu are un impact semnificativ asupra modelului.

### Concluzie:


În toate cele trei cazuri (trend, derivă și niciunul), **testul ADF nu respinge ipoteza nulă a unității de rădăcină** la un nivel de semnificație de 5%, ceea ce sugerează că seria **are unitate de rădăcină și nu este staționară**.

Deci, pentru a concluziona cele scrise mai sus, seria datelor este integrate de ordiul 1 și 2 . Pe baza acestor rezultate, putem afirma că seria de timp este nestaționară. În continuare voi efectua mai multe teste pentru a demonstra dacă seria este, într-adevăr, nestaționară sau nu.



Acest test arata că datele sunt autocorelate de ordinul 1, deci seria inițială este nestaționară. Acest model sugerează **o serie AR**, unde valorile curente sunt legate de valorile anterioare într-un mod linear.

## Series serie



Din grafic se observă că doar lagul 1 este semnificativ. Asta poate indica faptul că seria este potrivită pentru un model autoregresiv simplu (AR(1)). În imaginea prezentată nu par să existe vârfuri clare la anumite intervale periodice (laguri), ceea ce înseamnă că seria nu are componente sezoniere evidente.

- Dacă ACF scade treptat (cum este cazul aici), ar putea fi prezentă o componentă autoregresivă (AR).
- Combinația dintre ACF și PACF sugerează că seria poate fi modelată fie cu un model autoregresiv (AR), fie cu un model ARIMA, în funcție de alte teste.

```

46
47 acf(serie)
48 pacf(serie)
49 adf.test(serie)
50
51 seriemodel=auto.arima(serie,ic="aic",trace=TRUE)
52
53 acf(ts(seriemodel$residuals))
54 pacf(ts(seriemodel$residuals))

```

51:1 (Top Level) ⌵

Console Terminal x

R 4.3.1 · ~/ ↻

### Box-Ljung test

data: forecastserie\$resid  
X-squared = 7.6331, df = 20, p-value = 0.994

```

> tsdiag(seriemodel)
> acf(serie)
> pacf(serie)
> adf.test(serie)

```

### Augmented Dickey-Fuller Test

data: serie  
Dickey-Fuller = -2.2349, Lag order = 3, p-value = 0.4823  
alternative hypothesis: stationary

```

> |

```

Din testul ADF rezultă că se acceptă ipoteza nulă conform căreia seria de timp este nestaționară deoarece  $P\text{-Value} : 0.4823 > 0,05$ , deci nu se respinge ipoteza nulă, deci seria este nestaționară .

Pentru a staționariza seria am folosit funcția `auto.arima()`.

```
seriemodel=auto.arima(serie,ic="aic",trace=TRUE)
```

```
51 seriemodel=auto.arima(serie,ic="aic",trace=TRUE)
52
53 adf.test(serie)
54 adf.test(diferentavalue)
55 adf.test(diferenta2value)
56 acf(ts(seriemodel$residuals))
```

51:1 (Top Level) ▾

Console Terminal x

R 4.3.1 · ~/ ↻

```
training set 112.5937 6405.61 4151.284 -7.619081 20.67983
· seriemodel=auto.arima(serie,ic="aic",trace=TRUE)
```


```
ARIMA(2,0,2) with non-zero mean : 644.6132
ARIMA(0,0,0) with non-zero mean : 668.1912
ARIMA(1,0,0) with non-zero mean : 643.1243
ARIMA(0,0,1) with non-zero mean : 646.8495
ARIMA(0,0,0) with zero mean      : 718.924
ARIMA(2,0,0) with non-zero mean : 641.3041
ARIMA(3,0,0) with non-zero mean : 643.0581
ARIMA(2,0,1) with non-zero mean : 642.6317
ARIMA(1,0,1) with non-zero mean : 640.6343
ARIMA(1,0,2) with non-zero mean : 642.6327
ARIMA(0,0,2) with non-zero mean : 643.2958
ARIMA(1,0,1) with zero mean      : 644.8754
```

Best model: ARIMA(1,0,1) with non-zero mean




Folosind funcția `auto.arima` se obține cel mai bun model ARIMA, în cazul de față fiind  $ARIMA(1,0,1)$ . Pentru a verifica dacă acest model este staționar sau nu, reapelăm testele pe care le-am folosit mai devreme. Astfel, aplicăm din nou testul ACF, PACF și `ADF.test`.

## Series `ts(seriemodel$residuals)`



Deoarece toate valorile autocorelației (cu excepția uneia) sunt între limitele pragurile de semnificație statistică înseamnă că am staționarizat cu succes seria.

## Series `ts(seriemodel$residuals)`



La fel ca și în cazul anterior, deoarece toate valorile autocorelației sunt între limitele pragurile de semnificație statistică înseamnă că seria este staționarizată cu succes. Iar pentru o ultimă confirmare refacem testul ADF.

```
adf.test(ts(seriemodel$residuals))
```

```

58 acf(ts(seriemodel$residuals))
59 pacf(ts(seriemodel$residuals))
60 adf.test(ts(seriemodel$residuals))
61
62 forecastserie = forecast(seriemodel, lv = c(95), h=12)
63 forecastserie
64 plot(forecastserie)
65

```

62:1 (Top Level) ⌵

Console

Terminal x

R 4.3.1 · ~/ ↗

```

ARIMA(3,0,0) with non-zero mean : 643.0581
ARIMA(2,0,1) with non-zero mean : 642.6317
ARIMA(1,0,1) with non-zero mean : 640.6343
ARIMA(1,0,2) with non-zero mean : 642.6327
ARIMA(0,0,2) with non-zero mean : 643.2958
ARIMA(1,0,1) with zero mean      : 644.8754

```

Best model: ARIMA(1,0,1) with non-zero mean

```
> adf.test(ts(seriemodel$residuals))
```

Augmented Dickey-Fuller Test

```

data: ts(seriemodel$residuals)
Dickey-Fuller = -2.8795, Lag order = 3, p-value = 0.2342
alternative hypothesis: stationary

```

```
> |
```

P-value=0,2342 > 0,05 deci reziduurile nu sunt stationare.

Următorul pas este reprezentat de crearea unei prognoze a seriei de date folosind funcția `forecast()`.

```
forecastserie = forecast(seriemodel, lv = c(95), h=12)
```

```
forecastserie
```

```
plot(forecastserie)
```

```

61
62 forecastserie = forecast(seriemodel, lv = c(95), h=12)
63 forecastserie
64 plot(forecastserie)
65
66 Box.test(forecastserie$resid, lag = 1, type = "Ljung-Box")
67
62:1 (Top Level)

```

Console Terminal x

R 4.3.1 · ~/

warning message:

In forecast.forecast\_ARIMA(seriemodel, lv = c(95), h = 12) :  
The non-existent lv arguments will be ignored.

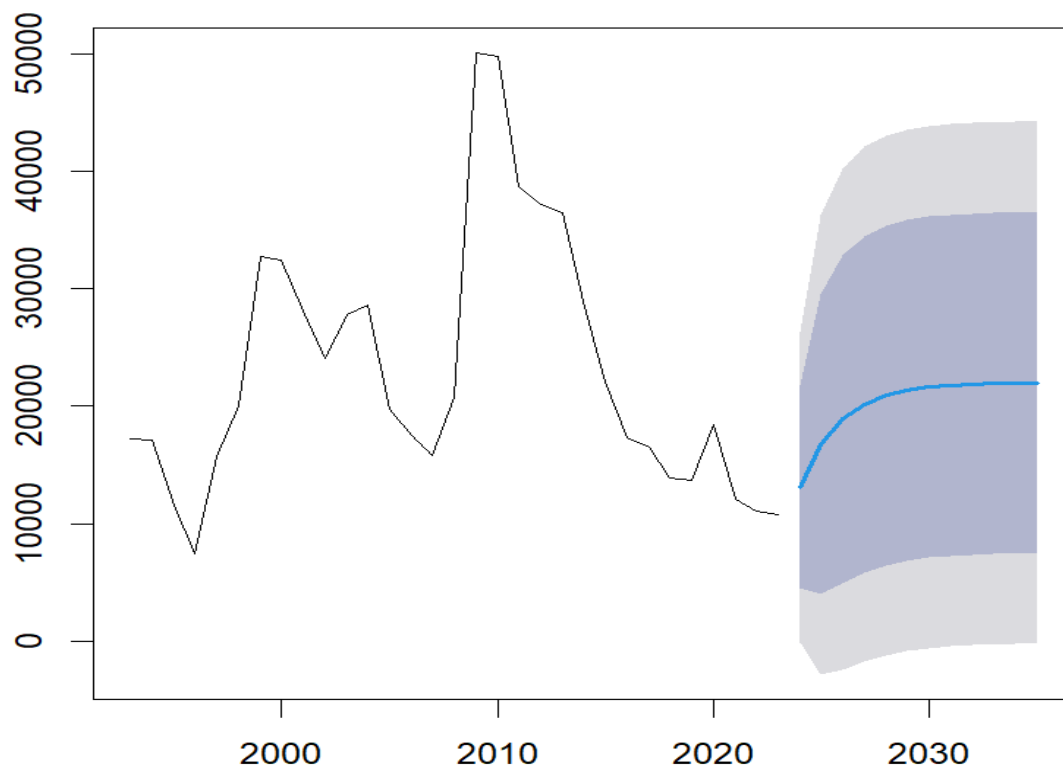
> forecastserie

	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
2024		13119.34	4481.638	21757.05	-90.88731	26329.57
2025		16734.60	3955.421	29513.78	-2809.46937	36278.67
2026		18879.36	4932.162	32826.55	-2451.03644	40209.75
2027		20151.73	5816.084	34487.38	-1772.75063	42076.22
2028		20906.57	6436.687	35376.46	-1223.20660	43036.35
2029		21354.38	6837.547	35871.21	-847.19942	43555.96
2030		21620.04	7086.723	36153.36	-606.75197	43846.84
2031		21777.65	7238.529	36316.76	-458.01516	44013.31
2032		21871.14	7329.987	36412.30	-367.63638	44109.93
2033		21926.61	7384.738	36468.49	-313.26615	44166.49
2034		21959.52	7417.392	36501.65	-280.74603	44199.79
2035		21979.04	7436.824	36521.26	-261.36021	44219.44

> plot(forecastserie)

>

### Forecasts from ARIMA(1,0,1) with non-zero mean



După realizarea predicției, am realizat testul Ljung-Box (Box.test) pentru a verifica dacă datele conțin probleme de autocorelație. În urma acestui test (efectuat cu valori ale lag-ului între 1-20) putem observa că p-value este întotdeauna mai mare decât valoarea pragului de semnificație de 0.05 => nu există autocorelație.

#### Box-Ljung test

```
data: forecastserie$resid  
X-squared = 0.024916, df = 1, p-value = 0.8746
```

```
> Box.test(forecastserie$resid, lag = 5, type = "Ljung-Box")
```

#### Box-Ljung test

```
data: forecastserie$resid  
X-squared = 0.32725, df = 5, p-value = 0.9971
```

```
> Box.test(forecastserie$resid, lag = 10, type = "Ljung-Box")
```

#### Box-Ljung test

```
data: forecastserie$resid  
X-squared = 3.7658, df = 10, p-value = 0.9573
```

```
> Box.test(forecastserie$resid, lag = 15, type = "Ljung-Box")
```

#### Box-Ljung test

```
data: forecastserie$resid  
X-squared = 7.0348, df = 15, p-value = 0.9567
```


```
> Box.test(forecastserie$resid, lag = 20, type = "Ljung-Box")
```

#### Box-Ljung test


```
data: forecastserie$resid  
X-squared = 7.6331, df = 20, p-value = 0.994
```

---


**Standardized Residuals**



**ACF of Residuals**



**p values for Ljung-Box statistic**



## *Bibliografie*

1. *Suportul de curs si seminariile*
2. *Sursa datelor pentru prima parte*

<https://fred.stlouisfed.org/series/QRON628BIS>

3. <http://statistici.insse.ro:8077/tempo-online/#/pages/tables/insse-table>